DATA ANALYSIS / 01

从购物行为到推荐候选

Retailrocket 全量公开日志 · SQL / Python / DuckDB

275.61万	140.76万	176.17万
原始事件记录	匿名访客	按30分钟间隔划分的访问

01 核心判断

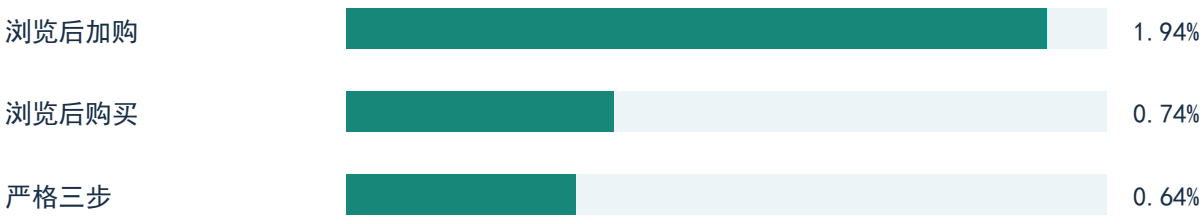
共同浏览比全局热门更能预测下一件被浏览的商品，适合作为推荐候选继续验证；但约38%的测试预测点完全回退热门，覆盖与商品时效性仍是优先问题。历史日志中的较高命中率不足以直接决定上线。

业务连接：内容电商连接商品发现与站内购买，本项目据此分析“下一商品发现→购买”的行为链。平台机制参考TikTok官方2025-03-31介绍，原文链接见docs/business_context.md；本数据不用于推断欧洲市场表现。

02 数据口径先于业务解释

完整读取2,756,101条事件，删除460条五字段完全重复记录，保留不同时刻的重复浏览；清洗后2,755,641条，非法记录0条。建立用户与访问表，并检查主键、关联前后行数与孤立记录。观测期间为2015年5月3日至9月18日（UTC）。

03 从浏览到购买：以同一商品、同次访问计数



共同分母为2,330,774个有浏览的“访客-访问-商品”配对。严格三步要求浏览、加购、购买按毫秒严格递增；加购与购买同毫秒不认定为先后。图中比例不是曝光CTR，也不是全站订单转化率。

04 行动建议

先审查跨访问购买、缺失加购与事件埋点，再决定是否把某一步视为流失。已有历史访问的浏览会话购买比例约1.51%，首次观测访问约0.49%；建议进一步分解活跃程度与商品结构，而非把差异直接归因于回访。

来源：Retailrocket / Kaggle，CC BY-NC-SA 4.0。原始数据和全部SQL在完整下载包保留；指标、方法与校验见仓库reports/及docs/。

离线结果如何支持下一步

模型冻结于2015-08-01之前 · 8月验证 · 9月测试

05 同一测试集上的推荐比较



28,166个有标签预测点；共同浏览命中5,147次，全局热门命中63次。配对差异为18.05个百分点，按访客聚类自助法95%区间为[17.54, 18.56]个百分点。

06 为什么这个比较可复查

只用训练期会话构建商品共现与热门排序。每次留出访问第一次浏览时预测下一次严格更晚的不同商品；两方法均推荐10件、去重且排除当前商品。3,166个未见商品标签仍留在分母。验证标签不跨入测试期，模型不按测试结果调参。

测试期200,912个预测点中只有28,166个带合规后续标签，结果描述这一子样本的下一商品预测。候选目录固定为199,510件训练商品；共同浏览推荐覆盖10.17%，完全回退热门37.93%。与8月相比测试命中率下降，应优先检查新商品与行为漂移。

07 实验演示给出的决定：暂不支持上线

独立模拟100,000名用户，分流检查p=0.574；对照购买比例2.559%，处理2.619%。差异0.061个百分点，95%区间[-0.136, 0.258]包含0。客服接触率护栏未触发，但转化证据不足，不作上线判断。

以2.5%为假设基线、识别0.15个百分点差异、双侧5%显著性和80%功效，规划约175,025人/组；本次模拟规模低于该目标。真实验证需按用户稳定随机、固定观察窗口，并在实验前锁定指标和停止规则。

08 可交付与复现

12个SQL文件、全量质量检查、边界测试、原始数据校验值、交互看板、逐项结果表及一页实验设计。全部指标按固定口径计算和检查，可通过公开输入与脚本复现；实验部分为独立模拟数据分析。